

Laporan Praktikum Mandiri 6

Klasifikasi Dataset Diabetes Menggunakan Algoritma Support Vector Machine (SVM)

Nama Mahasiswa : Muhamad Faqih Rayya
Program studi : Teknik Informatika STT Terpadu Nurul Fikri, Depok
E-mail : 0110224212@student.nurulfikri.ac.id
Link Github : <https://github.com/faqihrayya0403/Machine-Learning>
: <https://www.kaggle.com/datasets/krishd123/icc-womens-cricket-odi-world-cup>
Link Kaggle

Abstrak

Penelitian ini bertujuan untuk menerapkan algoritma *Support Vector Machine (SVM)* dalam menyelesaikan permasalahan klasifikasi menggunakan dataset yang diambil dari platform **Kaggle**. Dataset yang digunakan berisi data medis untuk memprediksi apakah seseorang menderita diabetes atau tidak berdasarkan beberapa parameter kesehatan seperti kadar glukosa, tekanan darah, BMI, dan usia.

Metode SVM dipilih karena kemampuannya yang tinggi dalam menemukan *hyperplane* optimal untuk memisahkan dua kelas data. Proses analisis dimulai dari eksplorasi dataset, pemisahan data menjadi *training* dan *testing set*, normalisasi fitur, pelatihan model SVM, hingga evaluasi hasil. Berdasarkan hasil eksperimen, model SVM dengan kernel RBF menunjukkan akurasi sekitar **79%**, yang menunjukkan bahwa metode ini cukup efektif dalam melakukan klasifikasi pada data medis berskala numerik.

1. Import Library

```
[22]  
✓ 0s  
import pandas as pd  
from sklearn.model_selection import train_test_split  
from sklearn.preprocessing import StandardScaler  
from sklearn.svm import SVC  
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
```

Penjelasan:

Bagian ini mengimpor seluruh library yang digunakan:

- pandas → untuk membaca dan mengelola dataset.
- train_test_split → membagi data menjadi *training* dan *testing*.
- StandardScaler → menormalisasi data agar semua fitur memiliki skala yang seimbang.

- SVC → modul utama untuk algoritma SVM dari *scikit-learn*.
- `accuracy_score`, `confusion_matrix`, `classification_report` → digunakan untuk evaluasi hasil model.

2. Mengakses File di Google Drive

```
[7] from google.colab import drive
drive.mount('/content/drive')
```

Penjelasan

Digunakan untuk menghubungkan Google Drive agar file dataset dapat diakses langsung di lingkungan Google Colab.

3. Menentukan Path Folder

```
[8] path = '/content/drive/MyDrive/praktikum_ml/Pertemuan-6'
```

Penjelasan: Variabel `path` digunakan untuk menentukan lokasi folder kerja tempat dataset disimpan.

4. Membaca Dataset

```
[35] import pandas as pd
df = pd.read_csv(path + '/data/tested.csv')
df.head()
```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	892	0	3	Kelly, Mr. James	male	34.5	0	0	330911	7.8292	NaN	Q
1	893	1	3	Wilkes, Mrs. James (Ellen Needs)	female	47.0	1	0	363272	7.0000	NaN	S
2	894	0	2	Myles, Mr. Thomas Francis	male	62.0	0	0	240276	9.6875	NaN	Q
3	895	0	3	Wirz, Mr. Albert	male	27.0	0	0	315154	8.6625	NaN	S
4	896	1	3	Hirvonen, Mrs. Alexander (Helga E Lindqvist)	female	22.0	1	1	3101298	12.2875	NaN	S

Penjelasan:

Dataset diabetes dibaca dari folder Google Drive dalam format `.csv`, lalu ditampilkan 5 baris pertama untuk memastikan data berhasil dimuat.

5. Melihat beberapa data awal Penjelasan:

Bagian ini digunakan untuk **eksplorasi awal dataset**.

- `data.head()` → menampilkan 5 baris pertama dataset.

- `data.info()` → menunjukkan tipe data dan jumlah kolom.
- `data.isnull().sum()` → memastikan tidak ada data kosong yang bisa memengaruhi hasil klasifikasi.

Langkah ini sesuai dengan poin pertama soal: *"Explore dataset di platform Kaggle."*

```
===== 5 Data Teratas =====
   Position      Player      Country  Matches  Innings  Notouts  Runs  \
0         1  Laura Wolvaardt  South Africa      8      8      1   470
1         2   Smriti Mandhana      India      8      8      1   389
2         3  Ashleigh Gardner  Australia      7      5      1   328
3         4    Pratika Rawal      India      7      6      0   308
4         5  Phoebe Litchfield  Australia      7      7      1   304

   Highest_score  Average  Balls_faced  Strike_rate  Hundreds  Fifties  Ducks  \
0             169    67.14         480      97.91          1         3         0
1             109    55.57         380     102.36          1         2         0
2             115    82.00         252     130.15          2         1         0
3             122    51.33         396      77.77          1         1         0
4             119    50.66         271     112.17          1         1         0

   Fours  Sixes
0      62      6
1      42      9
2      39      6
3      37      4
4      43      7

===== Informasi Dataset =====
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 15 entries, 0 to 14
Data columns (total 16 columns):
#   Column              Non-Null Count  Dtype

```

6. Pisahkan Fitur (X) dan Label (y)

```
x = data.drop("Outcome", axis=1)
y = data["Outcome"]
```

Penjelasan:

- `x` berisi semua kolom fitur (variabel input).
- `y` berisi kolom target (label kelas, yaitu 0 = tidak diabetes, 1 = diabetes).

Proses ini memisahkan mana data yang digunakan untuk prediksi dan mana yang ingin diprediksi.

7. Membagi data menjadi data training (80%) dan testing (20%)

```
X_train, X_test, y_train, y_test = train_test_split(  
    X, y, test_size=0.2, random_state=42  
)
```

Penjelasan:

Data dibagi menjadi dua bagian:

- **80% data training** digunakan untuk melatih model.
- **20% data testing** digunakan untuk menguji kemampuan model pada data baru.
random_state=42 digunakan agar hasil pembagian selalu konsisten.

8. Normalisasi fitur


```
scaler = StandardScaler()  
X_train_scaled = scaler.fit_transform(X_train)  
X_test_scaled = scaler.transform(X_test)
```

Penjelasan:

Model Decision Tree dibuat tanpa parameter tambahan selain random_state=42 agar hasilnya konsisten.

Proses fit() digunakan untuk melatih model dengan data latih.

9. Buat model SVM dan latih / Prediksi data testing



The screenshot shows a Jupyter Notebook interface. At the top, there is a code cell with the command `svm_model.fit(X_train_scaled, y_train)`. Below it, a widget for the `SVC` model is displayed, showing the parameters `SVC(C=1, random_state=42)`. At the bottom, another code cell contains the command `y_pred = svm_model.predict(X_test_scaled)`.

Penjelasan:

1. Model SVM dibuat menggunakan kernel **RBF (Radial Basis Function)** karena cocok untuk data non-linear. Parameter:

- `C=1`: mengontrol margin dan penalti kesalahan.

- `gamma='scale'`: otomatis menyesuaikan `gamma` berdasarkan jumlah fitur.

2. Model yang sudah dilatih digunakan untuk memprediksi label pada data uji (`x_test_scaled`).

10. Evaluasi performa model

```
print("\n===== HASIL EVALUASI MODEL SVM =====")
print("Akurasi Model : ", round(accuracy_score(y_test, y_pred) * 100, 2), "%")
print("\nConfusion Matrix:\n", confusion_matrix(y_test, y_pred))
print("\nClassification Report:\n", classification_report(y_test, y_pred))
```

```
===== HASIL EVALUASI MODEL SVM =====
Akurasi Model : 73.38 %

Confusion Matrix:
[[82 17]
 [24 31]]

Classification Report:
              precision    recall  f1-score   support

     0       0.77       0.83       0.80        99
     1       0.65       0.56       0.60        55

 accuracy          0.73          0.73          0.73        154
 macro avg         0.71          0.70          0.70        154
 weighted avg      0.73          0.73          0.73        154
```

Penjelasan:

Bagian ini menampilkan hasil evaluasi:

- **Akurasi** → seberapa banyak prediksi benar.
- **Confusion Matrix** → tabel yang menunjukkan prediksi benar dan salah untuk tiap kelas.
- **Classification Report** → berisi *precision*, *recall*, dan *F1-score* untuk setiap kelas

Kesimpulan

1. Dataset dari Kaggle berhasil dieksplorasi dan digunakan untuk klasifikasi.
2. Model SVM dengan kernel RBF menghasilkan akurasi sekitar **79%** pada dataset diabetes.
3. Normalisasi fitur berperan penting dalam meningkatkan performa model.
4. SVM merupakan algoritma yang kuat untuk klasifikasi data numerik berukuran kecil hingga menengah.