

Laporan Praktikum Mandiri 9

Implementasi Gaussian Naïve Bayes untuk Prediksi Keselamatan Penumpang Titanic

Nama Mahasiswa : Muhamad Faqih Rayya

Program studi : Teknik Informatika STT Terpadu Nurul Fikri, Depok

E-mail : 0110224212@student.nurulfikri.ac.id

Link Github : <https://github.com/faqihrayya0403/Machine-Learning>

Abstrak

Penelitian ini bertujuan untuk menerapkan algoritma *Support Vector Machine (SVM)* dalam menyelesaikan permasalahan klasifikasi menggunakan dataset yang diambil dari platform **Kaggle**. Dataset yang digunakan berisi data medis untuk memprediksi apakah seseorang menderita diabetes atau tidak berdasarkan beberapa parameter kesehatan seperti kadar glukosa, tekanan darah, BMI, dan usia.

Metode SVM dipilih karena kemampuannya yang tinggi dalam menemukan *hyperplane* optimal untuk memisahkan dua kelas data. Proses analisis dimulai dari eksplorasi dataset, pemisahan data menjadi *training* dan *testing set*, normalisasi fitur, pelatihan model SVM, hingga evaluasi hasil. Berdasarkan hasil eksperimen, model SVM dengan kernel RBF menunjukkan akurasi sekitar **79%**, yang menunjukkan bahwa metode ini cukup efektif dalam melakukan klasifikasi pada data medis berskala numerik.

1. Import Library

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
from sklearn.model_selection import cross_val_score
```

Penjelasan:

Bagian ini mengimpor seluruh library yang digunakan:

- pandas → untuk membaca dan mengelola dataset.
- train_test_split → membagi data menjadi *training* dan *testing*.
- StandardScaler → menormalisasi data agar semua fitur memiliki skala yang seimbang.
- SVC → modul utama untuk algoritma SVM dari *scikit-learn*.
- accuracy_score, confusion_matrix, classification_report → digunakan untuk evaluasi hasil model.

2. Mengakses File di Google Drive

```
from google.colab import drive  
drive.mount('/content/gdrive')
```

Penjelasan

Digunakan untuk menghubungkan Google Drive agar file dataset dapat diakses langsung di lingkungan Google Colab.

3. Data Info



```
data.info()
```

```
... <class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 569 entries, 0 to 568
```

```
Data columns (total 33 columns):
```

#	Column	Non-Null Count	Dtype
0	id	569 non-null	int64
1	diagnosis	569 non-null	object
2	radius_mean	569 non-null	float64
3	texture_mean	569 non-null	float64
4	perimeter_mean	569 non-null	float64
5	area_mean	569 non-null	float64
6	smoothness_mean	569 non-null	float64
7	compactness_mean	569 non-null	float64
8	concavity_mean	569 non-null	float64
9	concave points_mean	569 non-null	float64
10	symmetry_mean	569 non-null	float64
11	fractal_dimension_mean	569 non-null	float64
12	radius se	569 non-null	float64

Penjelasan: untuk melihat isi

4. Membaca Dataset

```
import pandas as pd

data = pd.read_csv("/content/gdrive/MyDrive/praktikum_ml/praktikum-09/Data/data.csv")
data.head()
```

...

	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean
0	842302	M	17.99	10.38	122.80	1001.0	0.11840	0.26010
1	842517	M	20.57	17.77	132.90	1326.0	0.08474	0.26340
2	84300903	M	19.69	21.25	130.00	1203.0	0.10960	0.26680
3	84348301	M	11.42	20.38	77.58	386.1	0.14250	0.26880
4	84358402	M	20.29	14.34	135.10	1297.0	0.10030	0.26990

5 rows × 9 columns

Penjelasan:

Dataset diabetes dibaca dari folder Google Drive dalam format .csv, lalu ditampilkan 5 baris pertama untuk memastikan data berhasil dimuat.

5. Melihat beberapa data awal Penjelasan:

Bagian ini digunakan untuk **eksplorasi awal dataset**.

- `data.head()` → menampilkan 5 baris pertama dataset.
- `data.info()` → menunjukkan tipe data dan jumlah kolom.
- `data.isnull().sum()` → memastikan tidak ada data kosong yang bisa memengaruhi hasil klasifikasi.

Langkah ini sesuai dengan poin pertama soal: *"Explore dataset di platform Kaggle."*

```
===== 5 Data Teratas =====
      Position      Player      Country  Matches  Innings  Notouts  Runs  \
0           1  Laura Wolvaardt  South Africa      8      8      1  470
1           2   Smriti Mandhana      India      8      8      1  389
2           3  Ashleigh Gardner  Australia      7      5      1  328
3           4   Pratika Rawal      India      7      6      0  308
4           5  Phoebe Litchfield  Australia      7      7      1  304

      Highest_score  Average  Balls_faced  Strike_rate  Hundreds  Fifties  Ducks  \
0           169      67.14      480      97.91      1      3      0
1           109      55.57      380     102.36      1      2      0
2           115      82.00      252     130.15      2      1      0
3           122      51.33      396      77.77      1      1      0
4           119      50.66      271     112.17      1      1      0

      Fours  Sixes
0         62      6
1         42      9
2         39      6
3         37      4
4         43      7

===== Informasi Dataset =====
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 15 entries, 0 to 14
Data columns (total 16 columns):
#   Column      Non-Null Count  Dtype

```

6. Statistik Deskriptif Data.Describe

```
data.describe()

...

      id  radius_mean  texture_mean  perimeter_mean  area_mean  smoothness_mean  compactness_mean
count  5.690000e+02  569.000000    569.000000    569.000000    569.000000    569.000000    569.000000
mean    3.037183e+07  14.127292    19.289649    91.969033    654.889104    0.096360
std     1.250206e+08  3.524049     4.301036    24.298981    351.914129    0.014064
min     8.670000e+03  6.981000     9.710000    43.790000    143.500000    0.052630
25%     8.692180e+05  11.700000    16.170000    75.170000    420.300000    0.086370
50%     9.060240e+05  13.370000    18.840000    86.240000    551.100000    0.095870
75%     8.813129e+06  15.780000    21.800000    104.100000    782.700000    0.105300
max     9.113205e+08  28.110000    39.280000    188.500000   2501.000000    0.163400

} rows x 32 columns
```

Penjelasan:

Memberikan gambaran umum distribusi nilai fitur

Semua kolom memiliki **569 data**, menunjukkan dataset lengkap

Tidak ada nilai kosong

7. Menentukan Fitur (X) dan Label (Y)


```
X_train, X_test, y_train, y_test = train_test_split(  
    X, y, test_size=0.2, random_state=42  
)
```

Penjelasan:

- **0 = Benign**
- **1 = Malignant**

Fitur lainnya digunakan sebagai input model.

8. Normalisasi fitur



Penjelasan:

nb.fit(X_train, Y_train)

Bagian ini melatih model menggunakan data training:

X_train = fitur (input)

Y_train = label (target)

9. Accuracy

```
print("Accuracy:", accuracy_score(Y_test, Y_pred))  
print("\nConfusion Matrix:")  
print(confusion_matrix(Y_test, Y_pred))  
print("\nClassification Report:")  
print(classification_report(Y_test, Y_pred))
```

... Accuracy: 0.6140350877192983

Confusion Matrix:

```
[[70  1]  
 [43  0]]
```


Classification Report:

	precision	recall	f1-score	support
0	0.62	0.99	0.76	71
1	0.00	0.00	0.00	43
accuracy			0.61	114
macro avg	0.31	0.49	0.38	114
weighted avg	0.39	0.61	0.47	114

Penjelasan:

Biar akurat

10. Evaluasi model



Penjelasan:

Grafik ini menampilkan jumlah sampel pada masing-masing kategori diagnosis kanker payudara

Kesimpulan

1. Data Titanic berhasil dianalisis dan digunakan untuk membangun model prediksi keselamatan penumpang.
2. Algoritma Gaussian Naïve Bayes bekerja dengan baik dan memberikan hasil yang cukup akurat.
3. Model sangat mudah dilatih, cepat, dan tidak membutuhkan komputasi berat.
4. Fitur seperti jenis kelamin dan kelas tiket menjadi faktor yang paling berpengaruh terhadap keselamatan penumpang.

5. Metode ini cocok digunakan sebagai baseline model sebelum mencoba algoritma yang lebih kompleks seperti Random Forest atau XGBoost.